



“Integración de LLMs en programación de APIs”

Sprint 2

Bernardo Corona Domínguez

NAO ID: 1085

Ciudad de México, México

30 de abril de 2025

CueBot es un asistente virtual basado en LLMs que tiene como objetivo facilitar la interacción con el acervo digital de la Universidad de Cuévano. Este sistema incluirá una API desarrollada con FastAPI y una interfaz gráfica simple con Gradio para pruebas iniciales. Posteriormente, se planea su integración a la página web de la universidad.

1. Backlog.

A) Historias de usuario.

A continuación, las 5 (cinco) historias de usuario:

1. Como investigadora, quiero subir archivos en distintos formatos (.pdf, .txt, .html) para que CueBot pueda analizarlos.
2. Como docente, quiero realizar preguntas en lenguaje natural a CueBot para obtener respuestas rápidas y relevantes del acervo digital.
3. Como desarrolladora, quiero contar con una API documentada que me permita integrar CueBot a otras plataformas fácilmente.
4. Como estudiante, quiero acceder a una interfaz amigable para interactuar con CueBot sin necesidad de conocimientos técnicos.
5. Como administradora del sistema, quiero monitorear el desempeño del LLM para asegurar que funciona eficientemente y cumple con las expectativas.

B) Tablas de registro.

Lista de Requerimientos	
Historias de usuario	Requerimientos
Como investigadora, quiero subir archivos en distintos formatos (.pdf, .txt, .html) para que CueBot pueda analizarlos.	Soporte para carga y procesamiento de archivos .pdf, .txt, y .html Conversión de contenido a texto plano y limpieza de datos antes del análisis.

Como docente, quiero realizar preguntas en lenguaje natural a CueBot para obtener respuestas rápidas y relevantes del acervo digital.	Motor de preguntas y respuestas utilizando un LLM conectado al acervo digital. Capacidad para contextualizar respuestas en función del documento consultado. Capacidad para contextualizar respuestas en función del documento consultado.
Como desarrolladora, quiero contar con una API documentada que me permita integrar CueBot a otras plataformas fácilmente.	Autenticación básica en los endpoints para uso controlado. Soporte para consultas asincrónicas (async) para mayor rendimiento.
Como estudiante, quiero acceder a una interfaz amigable para interactuar con CueBot sin necesidad de conocimientos técnicos.	Interfaz web en Gradio que permita probar la funcionalidad básica de CueBot. Opción para cargar archivos directamente desde la interfaz. Visualización del texto procesado y respuesta del LLM en pantalla.
Como administradora del sistema, quiero monitorear el desempeño del LLM para asegurar que funciona eficientemente y cumple con las expectativas.	Registro de logs de consultas y métricas de desempeño del modelo. Almacenamiento de logs en un archivo o base de datos para auditoría. Panel básico de administración para revisión de logs y estadísticas de uso. Mecanismo de reinicio o actualización manual del modelo en producción.

Lista Priorizada			
Requerimientos	Etapas	Estimación de tiempo	Entregables
Soporte para carga y procesamiento de archivos (.pdf, .txt, .html).	Fase 1 - Ingesta	2 semanas	Módulo de ingestión de archivos y normalización de texto.
Motor de preguntas y respuestas con LLM.	Fase 1 - Núcleo LLM	4 semanas	Integración de LLM con funciones de búsqueda y respuesta.
Desarrollo de API con FastAPI	Fase 1 - API	2 semanas	API funcional con <i>endpoints</i> de carga, consulta y documentación.
Interfaz web en Gradio.	Fase 2 - UI de prueba	2 semanas	Prototipo funcional para pruebas de interacción con CueBot.
Registro de logs y métricas de desempeño.	Fase 2 - Monitoreo	2 semanas	Sistema básico de monitoreo (<i>logging</i> , tiempos de respuesta).

Tabla 2. Lista de Requerimientos Priorizados

Requerimientos	Etapas	Estimación de Tiempo	Entregables
Soporte para carga y procesamiento de archivos (.pdf, .txt, .html)	Fase 1 – Ingesta	2 semanas	Módulo de ingestión de archivos y normalización de texto
Conversión de contenido a texto plano y limpieza de datos antes del análisis	Fase 1 – Ingesta	1 semana	Función de limpieza y preprocesamiento
Motor de preguntas y respuestas utilizando un LLM conectado al acervo digital	Fase 1 – Núcleo LLM	4 semanas	Sistema funcional de preguntas y respuestas
Capacidad para contextualizar respuestas en función del documento consultado	Fase 1 – Núcleo LLM	1 semana	Ajuste semántico en la generación de respuestas
Autenticación básica en los endpoints para uso controlado	Fase 1 – API	1 semana	Endpoints seguros con autenticación
Soporte para consultas asincrónicas (async) para mayor rendimiento	Fase 1 – API	1 semana	Endpoints optimizados para concurrencia
Desarrollo de API RESTful con FastAPI y documentación Swagger	Fase 1 – API	2 semanas	API documentada con Swagger UI
Interfaz web en Gradio para pruebas funcionales	Fase 2 – UI de prueba	2 semanas	Prototipo funcional accesible para usuarios
Carga de archivos desde la interfaz	Fase 2 – UI de prueba	1 semana	Función de carga integrada en la interfaz

Visualización del texto procesado y respuesta del LLM	Fase 2 – UI de prueba	1 semana	Vista previa del análisis y resultados
Registro de logs de consultas y métricas de desempeño	Fase 2 – Monitoreo	2 semanas	Sistema básico de observabilidad
Almacenamiento de logs en base de datos o archivo para auditoría	Fase 2 – Monitoreo	1 semana	Base de datos o archivo de registro persistente
Panel básico de administración para visualizar logs y estadísticas	Fase 2 – Monitoreo	1 semana	Interfaz de administración
Mecanismo de reinicio o actualización manual del modelo en producción	Fase 2 – Monitoreo	1 semana	Función de mantenimiento para el modelo